

Tytuł Roboczy: Modelowanie Finansowe w Obliczu Szoków Rynkowych: Porównanie Modelu Blacka-Scholesa i Deep Learningu na Przykładzie Studium Przypadku

Problem: Klasyczny model Blacka-Scholesa (B-S) opiera się na założeniach mocno matematycznych (np. stała zmienność, log-normalny rozkład zwrotów), które często nie odpowiadają realiom rynkowym, zwłaszcza w obliczu zewnętrznych "szoków rynkowych" (np. decyzje polityczne, przełomy technologiczne, wydarzenia geopolityczne). Prowadzi to do potencjalnie dużych błędów w wycenie i zarządzaniu ryzykiem w takich okresach.

Cel Projektu: Zbadanie ograniczeń modelu B-S w warunkach szoków rynkowych oraz ocena potencjału metod Deep Learning (DL) jako bardziej elastycznego narzędzia do modelowania dynamiki finansowej. Projekt ma na celu ilościowe porównanie zdolności obu podejść do odwzorowania rynku, w szczególności w kontekście **prognozowania zmienności**, w obliczu rzeczywistego, zidentyfikowanego szoku rynkowego.

Metodologia:

- **Studium Przypadku:** Wybór konkretnej spółki giełdowej (np. *Saab, Rheinmetall AG*), której notowania zostały istotnie zaburzone przez wyraźny, **precyzyjnie datowalny** szok zewnętrzny.
 - **Analiza założeń B-S:** Empiryczne zbadanie wpływu szoku na:
 - **Zmienność:** Obliczenie zmienności historycznej (np. w oknie kroczącym), wizualizacja jej skoku/niestabilności.
 - **Rozkład zwrotów:** Testy normalności (np. Shapiro-Wilk) przed i po szoku. Wizualizacja (histogramy, Q-Q ploty) w celu identyfikacji np. "grubych ogonów" (fat tails) i skośności.
 - **Symulacja Kontrfaktyczna (Baseline):**
 - Modelowanie przed szokiem: Dopasowanie modelu **GARCH** do danych **sprzed** szoku w celu uzyskania parametrów opisujących dynamikę zmienności w "normalnych" warunkach.
 - Symulacja "bez szoku": Użycie skalibrowanego modelu GARCH do wygenerowania stochastycznie np. 10k możliwych ścieżek **zmienności**, a następnie **ścieżek cenowych** (np. za pomocą procesów stochastycznych) od momentu rozpoczęcia szoku w przyszłość. Analiza nie tylko średniej, ale też **kwantyli (np. 5%-95%)** symulacji.
 - Ocena wpływu: Porównanie **rzeczywistej** ścieżki cenowej i zmienności po szoku z **rozkładem (pasmem)** wygenerowanych symulacji kontrfaktycznych.
 - **Model DL:** Zaprojektowanie i wytrenowanie odpowiedniej architektury DL (np. **zacząć od LSTM/GRU**, rozważyć Transformer dla długich zależności/okien) na danych historycznych.
 - **Główne zadanie:** Prognozowanie **przyszłej zrealizowanej zmienności** (obliczanej np. jako odch. std. log-zwrotów dziennych w oknie lub suma kwadratów zwrotów intraday).
 - **Dane wejściowe:** Przeszłe wartości zmienności zrealizowanej, zwroty, wolumen.
 - **Strategie treningu:**
 - * Model 1: Trenowany **tylko na danych sprzed szoku**, testowany na okresie szoku i po.
 - * Model 2: Trenowany na danych **obejmujących szok** (np. w oknie kroczącym lub na całym dostępnym zbiorze), aby sprawdzić zdolność adaptacji.
- Model 1 pokaże, jak sieć radzi sobie z anomalią, której nie widziała podczas treningu. Porównanie z Modelem 2 pokaże korzyści z "nauczenia się" szoku.
- **Porównanie:** Porównanie **prognoz zmienności** z:
 - Baseline 1: Prognoza z modelu GARCH dopasowanego **przed** szokiem.
 - Baseline 2 (opcjonalnie): GARCH z parametrami aktualizowanymi krocząco.
 - Model DL 1 (nieświadomy szoku).
 - Model DL 2 (adaptacyjny).
- Ocena względem **rzeczywistej zrealizowanej zmienności** za pomocą metryk.
- **Analiza jakościowa:** Jak wyniki DL korelują z momentem szoku, jak różnią się od statystycznych założeń B-S i symulacji kontrfaktycznej GARCH.

Główne wyniki: Projekt ma na celu dostarczenie empirycznych dowodów na ograniczenia B-S (a dokładniej jego założeń) w warunkach szoku rynkowego oraz zademonstrowanie, czy i w jakim stopniu metody DL mogą stanowić użyteczną alternatywę lub uzupełnienie (np. przez lepsze prognozowanie zmienności w niestabilnych warunkach), wykazując potencjalnie lepszą **zdolność adaptacji** do złożoności i niestacjonarności realnych rynków finansowych. Wyniki mogą mieć (albo nie mogą, ciężko powiedzieć) implikacje dla praktyki zarządzania ryzykiem.

Problemy:

- Nie mamy zbyt dużej wiedzy z modelu B-S (żadnej): Potrzebna literatura dotycząca **założeń B-S i ich ograniczeń**.
- Metryki do porównania prognoz zmienności: **RMSE (Root Mean Squared Error)**, **MAE (Mean Absolute Error)** ? Może QLIKE
- Symulacje stochastyczne: Skupić się na standardowym podejściu: **GARCH dla $\sigma(t)$ + procesy stochastyczne dla cen**. Reużycie kodu z modelowania epidemiologicznego jest chyba(?) ciężkie. Porównanie rzeczywistej ścieżki z **pasmem ufności (np. 5%-95%)** symulacji jest wystarczające, czy KDE potrzebne?
- **Architektura sieci:** powinno być ok, ewentualnie sensowny dobor hiperparametrow, żeby tego nie tuningować dwa lata